DocQA 实施与验收

> 配套文档：项目申报书 · 技术设计说明书 · 答辩讲稿

1. 实施策略

1.1 一句话

AI 写代码，人做决策。

- CodeAgent 负责：脚手架、解析器、索引器、CLI、Web、测试、文档初稿；
- 人负责：问题定义、架构取舍、契约评审、指标口径、验收与答辩。

1.2 五步渐进

步骤	名称	定位	状态	退出条件
1	doc2md	基础必做	已完成 Demo	5 类格式可解析；图片有释义与溯源
2	DocBase	基础必做	已完成 Demo	build/query/test 可运行；三路召回 + RRF + 精排
3	AGENTS.md	基础必做	已完成 Demo	约定四类；回答带 `[n]`；无据拒答
4	Service	可选扩展 · 团队级	已提供实现	watcher 可增量更新；事件可审计
5	Web	可选扩展 · 领域级	已提供实现	浏览器问答；引用可打开原文

1 – 3 步构建核心闭环，4 – 5 步面向团队与领域规模演进。

2. 工作分解（WBS）

2.1 第 1 步：doc2md

任务	产出	验收
格式识别与统一入口	`detect_doc_type` / `parse_document`	`.md/.pdf/.docx/.pptx/.txt` 均可解析
Markdown 图片处理	图片复制、重命名、引用替换	命名符合 `文档名_Page_Fig_标题`
PDF 解析	逐页文本 + 嵌入图	页码 exact；图片带图题
DOCX 解析	OOXML 段落/表格/图片	页码 estimated 明示
PPTX 解析	幻灯片文本 + 图片	一页幻灯片 = 一页
VL 释义	`VLDescriber` + Mock	释义写入正文引用块
manifest	`manifest.json`	包含图片、页码、统计、警告
失败处理	warning / 明确报错	不静默丢数据

2.2 第 2 步：DocBase

任务	产出	验收
语义切片	`chunker.py`	不跨页；代码块完整；超长段按句切
稠密索引	`vectors.json`	余弦召回可用
BM25	`sparse.json` 的 tf/df	精确术语命中
稀疏索引	归一化权重	与 BM25 互补
RRF	`retriever.py`	三路结果可融合
Reranker	真实/Mock	精排后 TOP-K 合理
增量建库	文档哈希 + chunk 复用	未变更文档不重算
test 模式	`evaluator.py`	recall@k / hit_rate / MRR
降级	route 级 try/except	单路异常不拖垮全链路

2.3 第 3 步：AGENTS.md

任务	产出	验收
四类约定	`AGENTS.md`	存在性/查询/溯源/产出
Agent 主流程	`answer.py`	意图、检索、自评、生成
引用契约	`Citation`	文档名/页码/图号/链接
无据不答	阈值 + 拒答	域外问题不编造
多轮检索	`max_rounds=2`	不足时自动扩展
结构化产出	Mermaid / 表格 / 步骤	与原文对照
CLI	`ask/query/eval`	可演示、可脚本化

2.4 第 4 步：Service（可选）

任务	产出	验收
目录快照	`_snapshot`	新增/修改/删除可识别
增量解析	`parse_document`	仅变更文件重解析
增量建库	`build_index(incremental=True)`	索引版本递增
事件日志	`data/watch.log`	JSONL 可审计
单次模式	`--once`	可用于 CI/手工触发

2.5 第 5 步：Web（可选）

任务	产出	验收
HTTP 服务	`web/server.py`	仅本机；无第三方框架
API	`/api/ask` `/api/stats` `/api/doc`	与 Agent 契约对齐
前端	`static/index.html`	问答、引用、原文抽屉
Mermaid	轻量 SVG 渲染	流程类问题图形化
响应式	CSS media query	窄屏可用

3. 演示脚本（可复现）

3.1 环境

```
cd DocQA
python3 --version          # 3.9+
python3 -m pip install -r requirements.txt   # 仅 PDF 解析需要 pypdf
./run.sh doctor
```

3.2 一键 Demo

```
./run.sh demo
```

预期输出（节选）：

```
DocQA Demo · 多模态文档 → 知识库 → Agent 问答

① 解析示例文档（doc2md · Mock VL 释义）
   5 个文档 · 3 张图片

② 构建三路混合索引（DocBase）
   32 个文本块 · 版本 2026.10.24-xxxxxx

③ Agent 问答（AGENTS.md 约定驱动）
Q: 分机注册后，呼叫是怎么转发到中继的?
**结论**：分机注册后，呼叫接续按以下六个步骤执行： [1]
...
**流程重绘（Mermaid）**
...
> 上图按知识库中的 Mermaid 源重绘，可与《02_分组转发设计》Page 2 · Fig 1
「分组转发呼叫接续流程」原图对照验证。
...
④ 检索质量评估（test 模式）
   recall@6=1.0  hit_rate=1.0  MRR=1.0  keyword_hit_rate=1.0
```

3.3 分步演示

```
# 1) 解析
./run.sh parse examples/docs --out data/parsed

# 2) 建库（首次全量）
./run.sh build data/parsed --index data/index

# 3) 只检索：看三路分数与路由
./run.sh query "SD5993 单板怎么复位？" --top-k 6

# 4) 问答：带轨迹
./run.sh ask "SD5993 单板怎么复位？命令是什么？" --show-trace

# 5) 流程类：Mermaid + 图号
./run.sh ask "分机注册后，呼叫是怎么转发到中继的？"

# 6) 无据不答
./run.sh ask "如何申请年假？"

# 7) 评估
./run.sh eval --index data/index --report data/eval_report.json

# 8) 增量建库
./run.sh build data/parsed --index data/index --incremental

# 9) Web
./run.sh serve --open

# 10) 目录监控（单次）
./run.sh watch --src examples/docs --once

# 11) 测试
make test
```

3.4 演示话术要点

1. **先把「找不到文件」的痛点讲具体**：只记得图、不记得文件名。
2. **展示解析产物**：`data/parsed/02_分组转发设计/document.md` 中图片已被替换为「图 + 释义 + 元信息」。
3. **展示三路分数**：`query` 输出中 `dense/bm25/sparse/routes` 同屏可见。
4. **展示引用**：回答末尾 `[1]` 可打开 `#page=2&figure=1`。
5. **展示拒答**：域外问题明确「无据不答」，并给最接近片段。
6. **展示约定**：打开根目录 `AGENTS.md`，说明这是「人与 Agent 的检索契约」。

---

4. 验收标准

4.1 功能验收

- [x] `parse` 支持 Markdown / PDF / DOCX / PPTX / TXT；
- [x] 图片按 `文档名_Page_Fig_标题` 命名，带 `#page=&figure=` 链接；
- [x] 解析产物包含 `document.md` / `assets/` / `manifest.json`；
- [x] `build` 产出三件套索引，支持增量；
- [x] `query` 返回三路分数与路由名；
- [x] `ask` 输出「结论 / 关键依据 / 溯源」；
- [x] 流程类回答包含 Mermaid，并给出原图 Page/Fig；
- [x] 命令类回答包含可执行命令与注意事项；
- [x] 版本类回答使用表格；
- [x] 域外问题输出「无据不答」，`citations=[]`；
- [x] `eval` 输出 recall@k / hit_rate / MRR / keyword_hit_rate；
- [x] `serve` 可浏览器问答并查看原文；
- [x] `watch --once` 可增量更新。

4.2 非功能验收

项	标准	现状
依赖	运行时标准库；PDF 可选 pypdf	满足
本地性	默认 Mock 不发网络请求	满足
Web 绑定	默认 `127.0.0.1`	满足
可测试	19 项单测/集成测试	通过
可回滚	索引版本 + 三件套	满足
可观测	trace + watch.log + warnings	满足
文档	项目书/技术设计/实施验收/讲稿/Deck	满足

4.3 指标验收

以 `examples/test_set.json` 8 条用例、TOP-6 为准：

指标	目标	实测
`recall@6`	⩾ 0.8	1.00
`hit_rate`	⩾ 0.8	1.00
`MRR`	⩾ 0.7	1.00
`keyword_hit_rate`	⩾ 0.7	1.00
无据拒答	域外问题必须拒答	通过
引用可追溯	100% 回答带 `[n]`	通过

> 演示集为作者自建小样本，指标只证明链路与口径；生产验收需用部门真实文档重建测试集。

5. 运维手册

5.1 日常

```
# 新增/修改文档后
./run.sh watch --src <文档目录> --parsed data/parsed --index data/index --once


# 或全量重建
./run.sh parse <文档目录> --out data/parsed
./run.sh build data/parsed --index data/index
```

5.2 索引备份/回滚

```
cp -r data/index data/index.bak.$(date +%Y%m%d)
# 回滚
rm -rf data/index && mv data/index.bak.YYYYMMDD data/index
```

索引目录自带 `version` 与 `created_at`，可用于审计。

5.3 模型切换

```
export DOCQA_MODEL_MODE=http
export DOCQA_BASE_URL=https://.../v1
export DOCQA_API_KEY=***
./run.sh build data/parsed --index data/index   # 换 Embedding 后必须重建
./run.sh doctor
```

> 切换 Embedding 模型后必须全量重建索引；`build_index` 会检测 `vectors.json.model` 并强制重算。

5.4 常见故障

现象	排查
`索引未就绪`	先 `./run.sh demo` 或 `build`
图片未解析	检查路径、扩展名；EMF/WMF 需先渲染
PDF 无文本	扫描件需 OCR； `pypdf` 是否安装
回答总是无据	覆盖率/相关度阈值过高；检查索引文档与分类
端点超时	检查 `DOCQA_BASE_URL` ；失败后会自动降级 Mock，重启进程恢复
Web 打开空白	检查 `data/index` 是否存在；浏览器控制台/网络面板

6. 风险登记册

ID	风险	概率	影响	应对	责任人
R1	内部模型端点不可用	中	高	Mock 降级 + 端点重试 + 告警	开发
R2	矢量图/扫描件信息丢失	中	中	渲染扩展 + OCR 兜底 + 明示告警	开发
R3	页码估算引发误引用	中	中	`page_mode=estimated` 明示；关键文档用 PDF/PPT	产品
R4	模型编造引用	低	高	只允许真实 Chunk 引用；回答后重编号；拒答机制	开发
R5	敏感数据外泄	低	高	本地运行、127.0.0.1、内部端点、密钥环境变量	全员
R6	规模增长导致检索变慢	中	中	增量、批量、向量库替换点	开发
R7	演示语料与真实文档差异	高	中	上线前用部门语料重建测试集	产品

7. 后续规划

7.1 近期（1–2 周）

- 接入真实 Qwen3-Embedding / Reranker / GLM / VL 端点，重跑 8 条用例并扩充到 50+；
- 增加 PDF 矢量图渲染（PyMuPDF）；
- 为 Web 增加流式输出与引用高亮。

7.2 中期（1–2 月）

- 团队级 Service：多目录、多分类、定时任务、监控告警；

- 领域级 Web：登录、权限、知识库切换、问答历史；
- 索引后端替换（SQLite/FAISS/Milvus），保持 `Retriever` 接口不变。

7.3 长期

- 文档自动归类与标签；
- 回答质量反馈闭环（点赞/纠错 → 测试集）；
- 与部门知识库、工单、Wiki 对接；
- 多模态检索（图搜图、图搜文）。

---

8. 交付检查表

- [x] 代码可运行：`./run.sh demo`
- [x] 测试通过：`make test`（19 项）
- [x] 示例数据：5 文档 + 3 图 + 8 条测试问题
- [x] 模型配置样例：`env.example`
- [x] 知识消费约定：`AGENTS.md` / `CLAUDE.md`
- [x] 项目书 / 技术设计 / 实施验收 / 答辩讲稿
- [x] 汇报 Deck：HTML + PDF
- [x] Web 截图与 Demo 输出留档

> **验收结论（演示环境）**：核心闭环 1 – 3 步可运行，4 – 5 步已有可演示实现；指标口径清晰，溯源链路完整，具备进入真实部门语料试点的条件。
